

제6회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	LightGBM 기반 전력 예측과 P90 피크 경보를 결합한 지능형 조업 일정 조정 시스템
팀명	FirstPlaceSolution
내용요약	[과제] 2021년 1 to 9월 공장 운영 데이터(6,168시간, 18개 변수)로 다음 날 24시간 전력을 예측하고, 기본요금을 정하는 최대 피크의 위험 조건과 저감 방안을 제시했습니다. [데이터 진단] 전력 패턴이 통째로 복제된 161일과 생산 기록이 누락된 15일을 찾아 평가에서 분리했습니다. 가동일만 보면 생산량과 일 최대 전력의 상관(0.85 → 0.094)이 사라지는 현상을 '생산은 필요조건, 고온은 증폭 요인'으로 해석했습니다. [예측 모델] LightGBM에 1주 전 패턴 중심 피쳐, 복제일 가중치, 피크 행 가중치를 적용해 7 to 9월 MAE 6.57, 피크 구간 MAE 12.49를 기록했습니다. 단순 규칙(목표선) 대비 오차를 각각 71%, 65% 줄였습니다. [피크 경보] 15분 최대를 직접 학습한 P90 모델로 위험일을 판정해 평가 69일에서 재현율 100%, 정밀도 95.5%를 기록했으며, 당일 이후 전력을 지운 176회 재실행으로 미래 정보 누수가 없음을 확인했습니다. [현장 활용] 설비 가동 분산(상시)과 경보일 피크 억제를 함께 쓰면 연 최대수요전력이 222에서 215.5로 낮아져, 기본요금 기준 연 43만 to 306만 원(전력 단위·계약 종별에 따라)을 절감할 수 있습니다. 작업 일정 조정을 권고하는 오프라인 운영 화면을 함께 제공합니다.

상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026년 10월 7일

팀장 : 최치훈 (서명)
팀원 : 남궁인성 (서명)
팀원 : 조선제 (서명)

(사)중소기업기술혁신협회 귀중

제1장. 데이터 이해 및 진단

● 데이터 분석 개요 및 예측 설정

- 분석 대상

- * 2021년 1월 1일부터 9월 14일까지 257일, 6,168시간의 공장 운영 데이터(18개 변수: 전력·생산·기상·날짜 및 단가)를 분석했습니다.

표 1 - 1. 변수 구성과 해석 (18개)

변수군	변수	값 범위	해석
전력	15 분·30 분·45 분·60 분	0 to 222	15 분 간격 측정값. 타깃과 같은 값이라 피처에서 제외
	평균	0 to 208 (평균 93.4)	네 값의 산술평균. 예측 타깃
생산	생산량	0 to 9,830, 43.1%가 0	시간당 생산 실적
	공장인원	0 to 48.4 (실수)	생산량과 순위상관 0.994 → 설비 투입 비율로 해석
	인건비	1.0 / 1.5	9 to 17 시 1.0, 그 외 1.5 → 주·야간 할증 계수
기상	기온	-12.0 to 33.4℃	22℃ 이상에서 냉방부하 발생
	풍속·습도·강수량	-	복제되지 않은 실측 기상
날짜·단가	날짜 / 시간	20210101 to 20210914 / 0 to 23	시간 컬럼은 7/13·7/15 손상 후 복구
	day / d / m	요일 / 일 / 월	달력 정보
	전기요금(계절)	109.8 / 167.2 / 191.6	1 to 2 월 / 3 to 5 월·9 월 / 6 to 8 월. 시간대별 차등 없음

- * 전력 평균은 15분 측정값 4개의 산술평균입니다. 전력 단위(순시 kW인지 15분 사용량인지)가 데이터에 없어, 금액 환산(제4장)에서는 두 경우를 함께 계산했습니다.

- 예측 설정

- * 예측 타깃은 다음 날(day-ahead)의 시간 평균 전력입니다. 생산 일정을 조율하려면 하루 전에 예측이 나와야 하기 때문입니다.
- * 예측 마감은 전날 자정(24시)입니다. 18시로 앞당기면 다음 날 18 to 23시를 예측할 때 24시간 전 실측이 미래 정보로 섞입니다.
- * 산업용 최대수요전력은 15분 단위로 산정되므로, 15분 값 4개 중 최대값(15분 최대)을 피크 분석과 경보의 두 번째 타깃으로 두었습니다. 시간 평균에 시각별 환산 계수를 곱하면 15분 최대와의 오차가 7.31에서 2.86으로 줄지만(실제 시간 평균을 넣은 진단값), 예측 시점에는 시간 평균도 예측값이므로 경보에는 15분 최대를 직접 학습한 모델을 씁니다(제3장).

● 공장 운영 패턴 및 변수의 의미 파악

- 파생 변수 해석

- * 전기요금은 계절별 단가일 뿐 생산과 무관합니다. 야간으로 작업을 미뤄도 요금 이득 없이 인건비(1.5배)만 오르므로, 비용을 줄이는 길은 최대수요전력 기본요금을 낮추는 것뿐입니다. 인건비와 공장 인원의 해석은 표 1-1과 같습니다.

- 전력 사용량의 구조 및 관련 변수

- * 전력 사용량은 교대 운전 체계와 밀접하게 연동됩니다. 평일 8 to 11시와 13 to 16시 등 특정 시간대에 부하가 집중되며, 전력 사용량이 23인 기저부하와 105인 중부하, 165의 고부하 상태로 뚜렷하게 구분할 수 있습니다.
- * 요일 패턴이 강해, 하루 전보다 지난주 같은 요일의 패턴과 훨씬 더 닮았습니다.
- * 전력은 생산량과 스피어만 순위상관 0.795로 가장 높은 상관을 보입니다. 그러나 생산량이 800 수준을 넘으면 전력 증가가 둔해져(포화), 생산량 단위당 전력은 오히려 줄어듭니다. 즉, 고부하 상태에서 에너지 효율이 높아집니다.




그림 1 - 1. 시간대별 전력 사용량과 생산량 (일 생산량 5000 초과 기준)




그림 1 - 2. 생산량 구간별 평균 전력

- * 기상의 경우 평상시엔 미미한 영향을 미치지만, 기온이 22℃ 이상인 경우 전력 사용량이 급격히 증가하게 되며 이를 '하계 냉방 부하'로 정의했습니다.




그림 1 - 3. 기온 범위에 따른 전력 사용량

- 피크 구간의 지배 변수 역전 현상

- * 전체 기간으로 보면 생산량이 많을수록 최대 전력도 높지만, 쉬는 날을 뺀 '가동일'만 보면 생산량과의 연관성은 거의 사라지고 기온의 영향이 커집니다.

표 1 - 2. 모집단에 따른 상관 역전 (피어슨, 스피어만 상관계수 비교)

모집단	일수	일생산량- 일최대전력 (피어슨)	일생산량- 일최대전력 (스피어만)	일평균기온- 일최대전력 (피어슨)	일평균기온- 일최대전력 (스피어만)
일 단위 전체 (휴무일 포함)	242	0.85	0.721	-0.003	0.11
일 단위 가동일만 (일 생산 5,000 초과)	156	0.094	0.133	0.366	0.428

- * '가동일'은 일 생산량 5,000 초과인 156일입니다. 임계값을 0으로 낮추면 부분 가동일이 섞여 상관이 0.73으로 오르지만, 10,000이나 15,000으로 높여도 0.08 수준이 유지되어 특정 임계값에 국한된 현상이 아닙니다.
- * 전력 최상위 시간대는 평소 바쁜 시간대보다 생산량이 적고 기온이 높았으며, 같은 날 안에서 비교해도 피크 시간대의 생산량이 더 적었습니다.
- * 이는 생산량이 무관하다는 뜻이 아니라, 생산이 이루어지는 날만 모아 생산량이 변별력을 잃은 것입니다. 생산은 피크의 '관문'이고, 관문을 통과한 뒤에는 기온이 위험의 크기를 좌우합니다.
- * 따라서 위험 조건을 '생산이 이루어지는 날의 고온'으로 정의했습니다. 생산은 필요조건, 기온은 증폭 요인인 2단 구조이며, 수치 근거는 제4장의 기온 × 생산 교차표에 제시합니다.

● 데이터 품질과 특이사항

- 데이터의 전반적 품질

- * 중복 기록은 없고 결측도 21행 수준이었습니다. 풍속·강수량은 선형보간하고, 공장 인원 결측은 공장이 멈춘 시간과 일치해 0으로 처리했습니다.

- 개별 특이사항과 조치 내용

- * 7월 13일·15일의 손상된 시간 기록은 원본 순서를 확인해 0 to 23시로 복구했습니다.
- * 전력값이 0으로 찍힌 구간은 기저부하조차 없어 정전이나 계측 누락으로 보고 학습과 평가에서 제외했습니다.
- * 일 최대 전력 30 미만인 날(일요일, 여름휴가 등)은 '휴무일'로 분류했습니다. 휴무 여부는 전날 알 수 있으므로 학습에 포함하되 별도로 표시하고, 직전 가동일의 값을 따로 활용했습니다.
- * 법정 공휴일은 완전 휴무일과 일찍 마치는 부분 가동일이 섞여 있어 별도 조건으로 다뤘습니다.
- * 생산량은 종일 0인데 전력을 크게 쓴 15일은 생산 기록 누락으로 보고, 학습에서는 제외하고 평가에는 원본 그대로 두었습니다.

- 증강(복제) 데이터 관련 이슈 (중요)

- * 161일은 24시간 전력 패턴이 다른 날과 완전히 같았습니다. 생산량과 날씨는 다른데 전력만 같은 경우로, 예를 들어 2021년 7월 28일과 7월 30일은 24시간 전력이 모두 일치합니다.
- * 복제일은 생산과 전력의 관계를 왜곡하므로 날짜 변수를 피처에서 빼 모델이 날짜를 외우지 못하게 했습니다. 또 복제일을 평가에 넣으면 암기만으로 오차가 절반까지 줄어 성능이 부풀려지므로, 평가는 고유일만으로 했습니다.

● 분석 및 평가 설계

- 학습·평가 대상과 검증 방식

- * 평가는 가동 중단·오류 시간대를 뺀 6,100행으로 고정했고, 학습은 여기서 생산 기록 누락 15일을 추가로 뺀 5,788행으로 했습니다. 평가셋은 모든 실험에서 같게 유지했습니다.
- * 데이터를 섞지 않고 시간 순서대로 검증했습니다. 핵심 검증 구간은 7 to 9월이며, 9월 데이터가 적어 완전히 독립적인 최종 검증 구간을 따로 두지 못한 점은 한계로 남깁니다.
- * 과제의 핵심이 최대 수요이므로, 전체 오차와 함께 '상위 5% 피크 구간'의 오차를 별도 지표로 평가했습니다. 이 지표는 설정 비교용 분석 기준(학습 구간 상위 5%)이며, 현장 경보 임계(15분 최대 직접 P90이 학습 구간 Q95 초과)와 그 검증은 제3장에서 다룹니다.

제2장. AI 예측모델 개발 및 성능평가

● 모델 개발 개요

- 문제 정의와 예측 설정

- * 과거 시차(Lag) 변수를 포함한 표 형태로 바꿔 회귀 문제로 접근했습니다. 입력은 달력·생산계획·기상·과거 전력, 출력은 다음 날 24시간의 시간별 평균 전력입니다.
- * 예측 시점(전날 자정)에는 알 수 없는 당일 15분 데이터와, 복제 그룹의 힌트가 될 수 있는 '일자 변수'는 피처에서 모두 뺐습니다.

- 입력 피처(Feature) 구성

- * 리드타임과 정보 가용성에 따라 full(36개, 하루 앞), no_plan(19개, 생산계획 없음), h7_full(32개, 24시간 전 시차 제외), h7_no_plan(12개)의 4개 세트를 만들었고, 통제 실험을 거쳐 h7_full에 시차 결측 대응 변수(L군)를 더한 h7_lag(34개)를 최종 세트로 채택했습니다.
- * 휴무 여부(is_off)는 당일 최대전력에서 파생되므로 달력군이 아닌 생산계획군으로 분류했습니다. 달력으로 취급하면 미래 정보를 당겨쓰게 됩니다. 이를 바로잡자 no_plan의 MAE가 13.36에서 25.32로 재측정되었고, 피처 보완 후 최종값은 19.93입니다(표 2-5). 현장 경보 경로(제3장)는 is_off 대신 생산계획만으로 만든 휴무 근사값(day_prod_zero)을 씁니다.

- 도메인 지식 기반의 파생변수 적용

- * 생산량 포화(800)는 상한을 찍은 prod_cap으로, 하계 냉방 부하는 기온 22°C 초과분 cool과 기온·습도를 결합한 불쾌지수 thi로 반영했습니다.
- * 휴무 구간이 시차 변수를 오염시키지 않도록 해당 구간을 결측으로 두고, 직전 가동일 같은 시각 값(lag_prev_op)과 휴무 길이(off_run_prev, days_since_off)를 따로 만들었습니다. 기저·중·고부하 3단계 운전 구조는 교대조(shift)와 전환 시각 변수로 사용했습니다.

● 동일 평가 조건의 설정

- 평가 조건의 고정과 판정 기준

- * 평가 대상이나 방식이 다르면 개선이 모델 덕인지 쉬운 데이터 덕인지 알 수 없으므로, 비교 전에 평가 조건을 고정했습니다. 모든 스크립트가 중앙 코드(model.py)의 같은 평가 기준을 불러옵니다.
- * 평가 대상: 고유일 중 가동 중단·손상을 뺀 5 to 9월 2,092행 (학습 데이터 양만 실험에 따라 조절)
- * 검증 방식: 시간순 롤링 폴드 (과거로 학습해 미래를 예측)
- * 판단 기준: 7 to 9월(1,708행) 성적을 우선하고 5 to 9월은 보조 지표로 병기 (5월은 학습 구간이

짧고 복제일이 많아 오차가 구조적으로 큼)

- * 평가 지표: MAE, RMSE와 함께 과제 핵심인 '상위 5% 피크 구간 MAE'
- * 개선 판정: 모든 설정을 시드 3개로 반복해 평균과 표준편차를 내고, 설정 간 차이가 시드 표준편차보다 작으면 개선으로 보지 않음

● 베이스라인 설정 및 비교 실험 설계

- 단순 규칙 4종과 목표선의 정의

- * AI가 넘어야 할 기준선으로 단순 규칙 4종(전체 평균, 전일 동일 시각, 전주 동일 시각, 요일×시각 평균)을 두었습니다.

표 2 - 1. 베이스라인 4종의 성능

단순 예측 규칙	MAE (7 ~ 9 월)	RMSE (7 ~ 9 월)	peakMAE (7 ~ 9 월)	MAE (5 ~ 9 월)	RMSE (5 ~ 9 월)	peakMAE (5 ~ 9 월)
전체 평균	53.21	60.39	90.32	52.14	59.39	90.1
전일 동일 시각	34.94	60.56	43.91	37.08	62.28	44.54
전주 동일 시각	22.92	47.71	40.09	23.64	48.32	39.98
요일×시각 평균	24.15	35.06	35.71	24.61	35.28	35.51

- * 평상시에는 전주 동일 시각(MAE 22.92)이, 휴가 직후처럼 패턴이 깨질 때는 요일×시각 평균(RMSE 35.06)이 유리했습니다. 하나에 의존하지 않고 지표별 최저값을 모아 목표선(MAE 22.9, RMSE 35.1, 피크 MAE 35.7)으로 정했습니다.

- 통제된 실험 원칙 (한 번에 하나만)

- * 기준 모델(LightGBM, full 피쳐, 엄격 학습 행, 복제일 가중치 원본)에서 한 번에 한 조건만 바꿔 효과를 추적하고, 효과가 확인된 요소를 마지막에 결합했습니다(설정 비교 24개).

- 비교 대상 모델 및 설정 기준

- * LightGBM과 RandomForest를 같은 피쳐(full), 학습 행, 폴드와 각 알고리즘의 기본 설정으로 비교했습니다(비교 실험 기준). 최종 모델은 이 출발점에서 통제 실험으로 도달한 설정이며(표 2-2), 모든 실험에 공통인 조건은 표 2-3과 같습니다.

표 2 - 2. 주요 모델 설정 대조

항목	비교 실험 기준 (LightGBM)	비교 대상 (RandomForest)	최종 모델 (LightGBM)
피쳐 세트	full (36 개)	full (36 개, 동일)	h7_lag (34 개)
목적함수	L1 (MAE 직접 최소화)	제곱오차 고정 (선택 불가)	L1 (MAE 직접 최소화)
트리 수 / 학습률	400 / 0.05	300 / 해당 없음	1,200 / 0.02 (느린 학습)
리프 수 / 리프 최소 표본	31 / 20	제한 없음 / 5	15 / 40 (얇은 나무)
피쳐 / 표본 샘플링	0.8 / 0.8	부트스트랩 (자동)	0.6 / 0.8
결측 처리	분기 규칙으로 직접 학습	-999 로 대체 후 학습	분기 규칙으로 직접 학습
복제일 가중치	1.0 (그대로)	1.0 (그대로)	0.3
피크 행 가중치	1.0 (적용 안 함)	1.0 (적용 안 함)	3.0 (학습 구간 상위 5%)
일 최대 추정	점 예측 그대로	점 예측 그대로	분위수 0.9 모델로 별도 산출

표 2 - 3. 공통 실험 조건

항목	값
학습 행	train_ok_strict 5,788 행 (가동중단·시간손상·생산기록 누락일 제외)
평가 행	고유일 2,092 행 (5 to 9 월) · 판단 기준 1,708 행 (7 to 9 월)
검증	시간순 롤링 폴드, 평가셋은 모든 설정에서 고정
시드	[0, 1, 2] 3 회 반복 학습, 시드 평균으로 보고
실험 규모	설정 비교 24 개 + 약점 공략 31 개 (각 시드 3 개 × 폴드)

- * 휴무 이력을 의도적 결측으로 둔 설계를 LightGBM은 분기 규칙으로 그대로 학습하지만, 대체값(-999)이 필요한 RandomForest는 이를 극단값으로 받아들입니다.
- * 하이퍼파라미터는 비교 단계에서 기본값으로 고정해, 개선이 튜닝이 아닌 데이터 처리와 피쳐에서 왔는지 확인했습니다. 최종 단계에서는 조합 효과를 검증해 조정했습니다.

● 핵심 실험 결과

- 알고리즘 비교: LightGBM 채택

- * LightGBM이 오차 지표 전반에서 앞섰습니다(시드 흔들림은 RandomForest가 0.07로 더 작음). 전체 MAE는 9.15 대 9.96으로 차이가 작지만, 피크 구간 MAE는 16.19 대 21.13으로 RandomForest가 약 30% 높았습니다.

표 2 - 4. 모델 2종 성능 (Error 중심) 비교

모델	MAE (7 ~ 9 월)	흔들림 (7 ~ 9 월)	RMSE (7 ~ 9 월)	peakMAE (7 ~ 9 월)	MAE (5 ~ 9 월)	결측 처리
LightGBM	9.15	0.53	14.11	16.19	10.41	분기 규칙으로 직접 학습
RandomForest	9.96	0.07	18.55	21.13	10.81	-999 로 대체 후 학습

- * LightGBM은 의도된 결측을 규칙으로 학습하고 MAE를 직접 최소화하는 L1 목적함수를 쓰는 반면, RandomForest는 트리 평균이 피크를 깎아 내립니다.

- 피쳐 세트 비교: '어제 데이터'의 역설

- * 직전 24시간 전(어제) 데이터를 제외한 h7_full 세트가 모든 데이터를 쓴 full 세트보다 오히려 오차가 1.10 더 낮았습니다.

표 2 - 5. 피쳐 세트 비교

피쳐 세트	피쳐 수	MAE (7 ~ 9 월)	흔들림 (7 ~ 9 월)	RMSE (7 ~ 9 월)	peakMAE (7 ~ 9 월)	MAE (5 ~ 9 월)
full (하루 앞)	36	9.15	0.53	14.11	16.19	10.41
h7_full (24 시간 전 시차 4 개 제외)	32	8.05	0.18	12.81	17.35	9.37
no_plan (생산계획 미제공)	19	19.93	0.31	37.96	27.29	21.16
h7_no_plan	12	17.51	0.49	36.61	22.81	17.59

- * 주 단위 패턴이 강한 공장 특성상, 어제(금요일) 데이터가 오늘(토요일)을 예측하는 데 노이즈로 작용한 것입니다. (전주 토요일 참조 시 오차 12.4 vs 어제 참조 시 오차 82.8)
- * h7_full은 일주일 앞 예측용으로 설계했지만 하루 앞에서도 가장 우수했고, 24시간 전 시차를 쓰지 않아 7일 전 정보에도 그대로 쓸 수 있습니다(제4장 표 4-7).

- 증강(복제) 데이터의 처리

- * 복제된 데이터를 아예 삭제하는 것은 학습량 부족을 초래해 성능이 악화되었습니다. 대신 데이터의 가중치를 낮추는 방식을 적용하자 성능이 일관되게 개선되었습니다.




그림 2 - 1. 복제일 가중치에 따른 성능

- * 두 피쳐 세트(full, h7_full)에서 7개 수준을 탐색했고 두 세트 모두 같은 곡선을 보였습니다. 학습에서 빠면 오차가 13 이상으로 오르고, 0.1 to 0.3에서 가장 낮으며 그 이후로는 완만하게 오릅니다(h7_full은 0.1과 0.3의 차이가 0.01).

- 긍정적 요소들의 결합 (조합 설정) 및 최종 모델 도출

- * h7_full과 복제일 가중치 0.3을 결합하자 MAE가 7.15로, 두 요소 단독 개선폭 합(2.43)의 82%인 2.00이 누적되었습니다. 이 1차 조합을 출발점으로 하이퍼파라미터 조합, 피크 행 가중치, 시차 걸측 대응 피쳐(L군)를 차례로 더해 6.57까지 낮췄습니다(표 2-6).

표 2 - 6. 개별 요소와 조합의 성능

설정	MAE (7 ~ 9 월)	흔들림 (7 ~ 9 월)	RMSE (7 ~ 9 월)	peakMAE (7 ~ 9 월)	MAE (5 ~ 9 월)
기준 (full · 복제일 그대로)	9.15	0.53	14.11	16.19	10.41
h7_full 단독	8.05	0.18	12.81	17.35	9.37
복제일 가중치 0.3 단독	7.82	0.59	11.18	15.81	9.57
h7_full + 가중치 0.3	7.15	0.12	10.83	16.54	8.77
h7_full + 가중치 0.1	7.14	0.2	10.67	17.85	8.9
누락일 포함 (학습 행 완화)	9.93	0.35	16.18	18.07	11.47
최종 (h7_lag + 피크가중 + 얇은나무·느린학습)	6.57	0.19	9.61	12.49	8.65

- 하이퍼 파라미터 민감도 검증

- * 단일 파라미터 10가지를 바꿔 보면, 목적함수를 제외한 변동 폭은 기본값 대비 ± 0.8 이내로 피쳐 세트(-1.10)나 복제일 가중치(-1.33)의 효과보다 작았습니다.
- * 개선 방향의 설정을 결합하면 효과가 커집니다. 얇은 나무(리프 15·최소 표본 40, 단독 -0.30)와 느린 학습(학습률 0.02·트리 1,200, 단독 -0.18)을 결합하자 -0.40이 누적되었습니다.
- * 피크 가중과 샘플링 0.6을 더하면 전체 MAE는 6.75에서 6.79로 시드 표준편차 안에서 소폭

후퇴하지만, 피크 구간 MAE가 14.89에서 12.75로 2.14 개선되어 이를 택했습니다.

표 2 - 7. 파라미터 조합 효과

설정	MAE	흔들림	기준 대비	RMSE	peakMAE
h7_full + 가중치 0.3	7.15	0.12	0	10.83	16.54
깊은 나무 (리프 63 · 최소표본 10)	8.11	0.03	0.96	13.47	20.73
얕은 나무 (리프 15 · 최소표본 40)	6.85	0.04	-0.3	10.16	14.3
느린 학습 (학습률 0.02 · 트리 1,200)	6.97	0.09	-0.18	10.53	16.39
얕은 나무 + 느린 학습	6.75	0.12	-0.4	10.11	14.89
얕은 나무 + 피크행 가중 3 배	6.92	0.18	-0.23	10.06	12.97
얕은 나무 + 느린 학습 + 피크가중 + 샘플링 0.6	6.79	0.13	-0.36	9.72	12.75
최종 (위 + L 군 피쳐)	6.57	0.19	-0.58	9.61	12.49

- * 목적함수만은 단독으로도 결정적이었습니다. L1을 L2로 바꾸면 MAE가 7.15에서 9.25로 악화(+ 2.10)되어, 평가지표(MAE)를 직접 최소화하는 구조가 필요함을 확인했습니다.

- 피크 과소예측의 해소

- * 오차 분석에서 드러난 두 약점(피크 과소예측, 공휴일 과대예측)을 겨냥해 31개 설정을 추가 실험했습니다(목적함수, 분위수 회귀, 피크 행 가중치, 선형 모델 혼합 등).

표 2 - 8. 약점 공략 실험 요약 및 판정 기준

설정	MAE	흔들림	RMSE	peakMAE	판정
1차 조합 (h7_full + 가중치 0.3)	7.15	0.12	10.83	16.54	-
목적함수 L2	9.25	0.24	14.38	19.43	기각
분위수 0.6	7.28	0.12	10.42	13.78	보류 (peakMAE 는 우수)
분위수 0.9	14.12	0.43	24.12	8.13	일 최대 추정 전용으로 채택
피크행 가중 3배	7.07	0.16	10.22	14.3	채택
피크행 가중 6배	7.09	0.1	10.28	12.28	대안 보류 (피크 우선 시)
Ridge 단독	15.86	0	21.62	20.18	기각
LGBM+ Ridge 7:3	8.62	0.18	11.46	17.14	기각
공휴일 상호작용 피쳐	7.23	0.33	10.78	16.54	기각
공휴일 행 가중 5배	8.11	0.27	11.95	16.56	기각

- * 학습 구간 상위 5% 행의 가중치를 3배로 올리는 방식이 가장 효과적이어서, 전체 MAE를 유지하며(7.15 → 7.07) 피크 구간 MAE를 16.54에서 14.30으로 낮췄습니다.
- * 분위수 0.9 모델은 피크 구간 MAE를 8.13까지 낮췄지만 전체 MAE가 14.12로 나빠져, 점 예측 대신 '일 최대 전력 추정' 전용으로 분리했습니다. 현장 피크 경보는 이와 별도로 15분 최대를 직접 학습한 P90 모델을 씁니다(제3장).

- * Ridge 단독과 LightGBM 혼합은 모두 열세(MAE 15.86, 피크 20.18)여서 기각했고, 공휴일 대책(상호작용 피쳐, 행 가중치)은 학습 구간 공휴일 표본이 2일뿐이어서 기각했습니다.
- * 피크 행 가중 6배는 피크 MAE를 12.28로 더 낮추지만 전체 MAE(7.09)가 3배(7.07)와 시드 편차 안에서 같아, 평상시 정확도를 우선해 3배를 채택하고 6배는 대안으로 남겼습니다.

- 시차 변수 결측 대응 (L군 피쳐 도입)

- * 휴무 구간을 의도적으로 결측 처리한 결과 과거 전력 입력의 결측 비율이 21.5%였고, 하계휴가가 긴 8월은 1주 전 값이 통째로 빈 행이 276개였습니다.
- * 1주 전 값의 결측 여부(lag168_na)와 1주 전·2주 전·최근 4주 평균 중 유효한 값(lag_best)을 추가하자 결측 비율이 13.6%로 줄고 MAE가 6.79에서 6.57로 개선되었으며, 개선분은 8월에 집중되었습니다.

● 최종 모델 선정 및 성능 평가

- 최종 스펙

- * 최종 모델은 LightGBM, h7_lag(34개), 학습 5,788행, 복제일 가중치 0.3, 피크 행 가중 3배, 얇은 나무(리프 15·최소 표본 40)와 느린 학습(학습률 0.02·트리 1,200)이며, 시드 3개 평균으로 보고합니다.
- * 일 최대 전력은 점 예측의 피크 과소평가를 피하기 위해 분위수 0.9 모델로 따로 추정합니다.
- * 복제일 가중치 0.1과 0.3은 MAE 차이가 0.01(7.14 vs 7.15)로 시드 표준편차보다 작아, 피크 구간 MAE(16.54 vs 17.85)와 시드 안정성(0.12 vs 0.20)이 나은 0.3을 골랐습니다.

- 목표선 대비 최종 성능

- * 핵심 판단 기준인 7 to 9월 기준 MAE 6.57, RMSE 9.61, 피크 구간 MAE 12.49를 기록하며 단순 규칙(목표선) 대비 오차를 각각 71%, 73%, 65% 감소시켰습니다. 결정계수(R²)는 0.975, 예측 오차가 ± 10 이내인 비율은 77.1%입니다(두 값은 시드 3개의 예측값 평균 기준이며, 같은 기준의 MAE는 6.51입니다. 제3장).
- * 피크 구간 개선폭(65%)이 전체(71%)에 근접했으며, 1차 조합(16.54) 대비로도 25%를 추가로 줄였습니다.

표 2 - 9. 최종 모델과 목표선

기준	평가 행 수	목표선 MAE	모델 MAE	MAE 개선율 (%)	목표선 RMSE	모델 RMSE	RMSE 개선율 (%)	목표선 피크 MAE	모델 피크 MAE	피크 MAE 개선율 (%)
7 ~ 9 월 (판단 기준)	1708	22.92	6.57	-71	35.06	9.61	-73	35.71	12.49	-65
5 ~ 9 월 (전체)	2092	23.64	8.65	-63	35.28	16.56	-53	35.51	12.69	-64

- * 월별로는 휴가 직후 8월에 목표선(27.47)과 모델(6.60)의 격차가 가장 커, 주간 패턴이 끊겨 단순 규칙이 무너지는 구간을 모델이 메웠습니다. 5월(20.27)은 학습 구간이 4개월뿐이고 대부분이 복제일이라 오차가 큼니다.

● 모델 참조 변수 분석 (SHAP)

- 전체 구간의 변수 중요도

- * 가장 크게 기여한 변수는 당일 생산계획(prod 10.0%, day_prod 8.3%, prod_next 7.8%)과 과거 전력(lag168 8.9%, lag336 7.2%)이며, 정보군별로는 생산계획 48.7%, 과거 전력 33.7%, 기상 9.6%, 달력 8.0%입니다. 평상시 기준선은 생산계획과 과거 패턴이 정합니다.

- 피크 구간에서의 기여 구조 변화 (SHAP 분석)

- * 분석 대상을 '상위 5% 피크 구간'으로 좁히면 변수 기여 구조가 뚜렷하게 달라집니다. 피크 구간에서는 전체 구간 대비 과거 전력의 영향력(|SHAP|)이 1.50배, 기상 변수가 1.56배 증가한 반면, 최상위 변수였던 생산계획의 기여도는 0.95배로 오히려 감소했습니다.

표 2 - 10. 정보군별 기여도

정보군	gain 중요도 합계(%)	전체 평균 SHAP	피크 구간 평균 SHAP	피크/전체 배율
생산계획·휴무	48.7	42.28	40.07	0.95
과거 전력	33.7	22.46	33.7	1.5
기상	9.6	1.97	3.07	1.56
달력	8	6.46	9.25	1.43

- * 이는 제1장에서 가동일만 떼어 보았을 때 생산량의 영향이 약해지고 기온의 영향이 커진 것과 같은 방향입니다. AI 모델 역시 부하가 급증할 때 생산계획보다 기상과 과거 패턴에 더 높은 가중치를 두도록 학습한 것입니다.
- * 특히 파생 변수인 불쾌지수(thi)는 피크 구간에서 기여도가 2.25배, 냉방 부하(cool)는 1.54배로 크게 증가한 반면, 원본 기온(temp) 변수의 기여도는 0.92배로 거의 변하지 않았습니다. 피크 구간에서 모델이 원본 기온보다 도메인 지식으로 가공한 파생 변수를 더 많이 활용했다는 뜻입니다.

표 2 - 11. 각 파생변수의 기여도

1 장의 도메인 발견	파생 변수	정의	gain 중요도	피크 구간 SHAP 배율
생산량 800 부근에서 전력 포화	prod_cap	생산량을 800 에서 절단	4.72%	1.14 배
생산량 분포가 한쪽으로 쏠림	prod_log	$\log(1 + \text{생산량})$	2.07%	1.04 배
기온 22°C 이상에서 냉방부하 발생	cool	$\max(\text{기온} - 22, 0)$	1.21%	1.54 배
기온과 습도가 함께 작용	thi	불쾌지수 (기온·습도 결합)	2.40%	2.25 배
전일보다 전주 동일 요일이 유사	lag168 / lag336 / lag_week_mean4	1 주 전·2 주 전· 최근 4 주 평균 동시각	22.42%	1.51 배
휴무 기간이 다음 주 시차를 오염	lag 결측 처리 + lag_prev_op	휴무·중단 구간은 결측, 직전 가동일 동시각을 별도 변수로	-	-
휴무 길이에 따라 복귀일 부하가 다름	off_run_prev / days_since_off	직전 연속 휴무 일수 / 마지막 휴무 이후 경과일	1.46%	0.69 배
부하가 기저·중·고 세 단계로 구분	shift / is_transition	야간·점심·주간 구분 / 전환 시각(7·12·17 시)	2.01%	1.44 배
휴무 여부가 타깃에서 유도된 값	day_prod_zero	생산계획만으로 만든 휴무 근사값	1.77%	0.39 배

- * 단, 피크 구간에서도 기상 변수의 절대 기여도(3.07)는 과거 전력(33.70)에 크게 못 미칩니다.
따라서 기온은 공장의 기본 부하를 결정하기보다, 주간 고부하 상태에 추가적인 전력을
소모하게 만드는 '증분(Increment)' 요소로 작용한다고 볼 수 있습니다.

● 피크 관점의 심층 분석 및 한계점

- 피크 관점의 성능 최적화

- * 피크 구간의 최종 MAE는 12.49이며 평균 오차는 +11.92를 기록하여 예측값의 89.7%가
실제보다 낮게 나타났습니다. 피크 보정 전(16.54, 92.9%) 대비 오차는 뚜렷하게 개선되었으나,
점 예측 고유의 파소 경향 자체는 잔존했습니다.

표 2 - 12. 피크 관점의 성능

지표	값	비고
시간 단위 MAE	6.57	설정 비교표 기준 (시드별 지표의 평균)
피크 구간 MAE	12.49	학습 구간 상위 5%
피크 구간 평균 오차	11.92	양수 = 과소예측
피크 구간 과소예측 비율(%)	89.7	-
일 최대 MAE (점 예측)	10.93	가동일 54 일
일 최대 평균 오차 (점 예측)	6.8	양수 = 과소예측
일 최대 MAE (분위 0.9)	8.61	추정량 교체 후
일 최대 평균 오차 (분위 0.9)	-0.16	편향이 사실상 사라짐
피크 시각 정확히 일치(%)	20.4	-
피크 시각 ± 1 시간 이내(%)	31.5	-
예측 상위 3 시간 안에 포함(%)	66.7	-
예측 지목 시각의 실제 전력 수준(%)	96.2	그날 실제 최대 대비, 중앙값

- * 일 최대 전력을 점 예측 모델로 추정할 경우 MAE 10.93 및 평균 6.80의 과소예측 편향(Bias)이 발생합니다. 그러나 추정량을 분위수 0.9 모델로 교체하자 MAE가 8.61로 21% 감소하고 평균 편향이 -0.16으로 거의 사라졌습니다.
- * 단, 이러한 분위수 교체 효과는 피크가 실제로 높았던 7월과 8월 구간(15.97 $\rightarrow$ 11.36, 7.98 $\rightarrow$ 6.65)에서 뚜렷하게 발현되며, 5월과 9월은 과대 추정으로 인해 소폭 악화되는 양상을 보입니다.
- * 피크 시각 적중률은 정확히 일치 20.4%, ± 1 시간 31.5%, 예측 상위 3시간 포함 66.7%입니다. 주간에 비슷한 높이의 봉우리가 여럿이기 때문이며, 모델이 지목한 시각의 실제 전력은 그날 최대의 96.2%(중앙값)입니다. 따라서 경보는 '특정 시각'보다 '당일의 피크 위험 여부'를 알리도록 설계했습니다.

- 분석의 한계 및 후속 과제

- * 7 to 9월 성능을 설정 선택에도 썼으므로 선택 편향이 있고, 독립 검증 구간(Hold-out)이 없어 현장 성능은 이보다 낮을 수 있습니다. 생산량과 기상은 실측값을 계획·예보로 가정해 넣었으므로 계획·예보 오차만큼 성능이 더 낮아질 수 있습니다.
- * 시간 단위 점 예측은 현 구조에서 한계에 가깝습니다. 단조 제약, L2 정규화, 가지치기, 최근 데이터 가중 등 15가지 기법을 두 차례 검증했으나 모두 기각했습니다.
- * 남은 여지는 튜닝보다 데이터 정합성에 있습니다. 테스트 구간의 당일 생산계획이 누락 없이 제공되면 휴지 구간 규칙 기반 후처리로 MAE를 약 0.40 더 줄일 수 있을 것으로 보입니다.

제3장. 영향요인 및 오류분석

● 오류 분석의 설계

- 분석의 기준과 범위

- * 제2장 최종 모델의 예측값을 행 단위로 저장해 조건별·시간대별·날짜별 오차와 정보의 미탐지·오정보를 분석했습니다. 평균 성능만으로는 '어떤 조건일 때 모델을 믿을 수 있는지' 알 수 없기 때문입니다.
- * 본 장은 시드 3개 예측값의 평균(단일 예측 집합) 기준이라, 시드별 지표의 평균인 제2장(MAE 6.57)과 집계 방식이 다르며 같은 7 to 9월의 MAE는 6.51입니다.

● 모델이 안정적으로 작동하는 조건

- 오차가 최소화되는 신뢰 구간

- * 핵심 평가 구간인 7 to 9월(CORE, 1,708행)의 예측 MAE는 6.51이며, 편향(Bias)은 -0.48로 사실상 0에 수렴합니다. 이는 평상시 운전 조건에서 모델이 체계적으로 과대 혹은 과소 예측하는 경향이 없음을 의미합니다.

표 3 - 1. 조건별 오차 구조

구분	조건	행 수	MAE	편향	과소예측 비율(%)
기준	전체 (5 to 9 월)	2092	8.59	-1.63	45.4
기준	CORE (7 to 9 월)	1708	6.51	-0.48	44.1
안정	주말	629	3.31	-0.88	44
안정	휴무 직후	480	6.96	-2.8	34
주의	고온 가동(기온>22℃ & 생산>0)	846	9.18	0.13	46.8
주의	전환시각(7·12·17 시)	261	8	-1.74	47.5
실패	고생산(900+)	440	11.61	2.36	53
실패	피크 구간(학습구간 상위 5% 기준)	189	12.68	12.14	89.9
실패	마지막 생산시간 이후	208	17.69	-14.15	39.4
실패	법정공휴일	96	37.03	-36.4	10.4
실패	공휴일 & 생산종료 이후	31	91.47	-91.47	0

- * 비가동 구간은 매우 정확합니다. 주말 MAE 3.31(일요일 1.73, 토요일 5.00), 완전 휴무일(8월 15일) 1.0입니다.
- * 휴무 직후 복귀일도 MAE 6.96으로 평상시 수준이어서, L군 피처와 휴무 길이 변수가 의도대로 작동했습니다.
- * 학습 데이터가 쌓일수록 오차가 줄었습니다(7월 7.06 → 8월 6.51 → 9월 5.45).

● 모델이 실패하는 조건

- 실패 1. 부분 가동 공휴일 (최대 오차 발생 요인)

- * 법정공휴일 96행의 MAE는 37.03으로 전체(8.59)의 4.3배이고, 편향 -36.40은 크게 과대예측했다는 뜻입니다. 공휴일 중 조업 종료 이후(31행)는 MAE 91.47로 전량 과대예측이었습니다.
- * 실패는 공휴일 전체가 아니라 '생산 계획은 있으나 일찍 끝나는 부분 가동일'에 집중됩니다. 완전 휴무일(8월 15일)은 MAE 1.0, 정상 조업에 가까운 8월 16일은 16.5였지만, 5월 5일(일 생산 2,190)은 실제 평균 45.8을 116.1로, 5월 19일(2,990)은 42.1을 101.4로 예측했습니다. 생산계획이 들어오면 하루 종일 가동으로 판단하기 때문입니다.
- * 휴무 판정 변수(is_off)가 종일 휴무(일 최대 30 미만)만 식별해 부분 가동일을 구분하지 못하는 것이 원인입니다. 공휴일 대책 피쳐는 학습 구간 공휴일이 2일뿐이어서 기각되었으므로(제2장), 현장 데이터 확보로 풀어야 할 과제입니다.

- 실패 2. 피크 구간의 잔존 과소예측 현상

- * 상위 5% 피크 구간(189행)은 MAE 12.68, 편향 + 12.14로 예측의 89.9%가 실제보다 낮습니다. 피크 가중과 일 최대 모델 분리로 크게 완화했지만, 점 예측의 평균 회귀 성향은 남았습니다.
- * 고생산 구간(440행)은 편향 + 2.36으로 약한 과소, 고온 가동 구간(846행)은 편향 + 0.13으로 치우침이 없습니다. 기온에 따른 부하 증가는 학습했고, 남은 과소예측은 극단값을 평균 쪽으로 끌어내리는 점 예측의 특성 때문입니다.
- * 시간대별로는 설비가 기동하며 전력 부하가 급변하는 '오전 상승 구간'의 예측이 가장 취약했습니다(5 to 9월 전체 기준 11시 MAE 12.85, 8시 12.47, 9시 11.16 순).

- 실패 3. 현장 생산 기록 누락일

- * 생산량은 0인데 전력이 100을 넘는 28행에서 MAE 7.91, 편향 + 6.40이 낮습니다. 제1장 조치대로 이 15일은 평가에 원본 그대로 두었으므로, 모델 오류가 아니라 입력 데이터 결함이 반영된 오차입니다.

- 실패 4. 학습 구간이 절대적으로 짧은 초기 구간 (5월)

- * 5월(336행) MAE는 20.23으로 전체의 약 2.4배입니다. 학습 가능 기간이 4개월뿐이고 대부분이 복제일인 탓도 있지만, 부분 가동 공휴일 이틀(5/5, 5/19, 48행)을 빼면 12.71로 떨어져 상당 부분이 공휴일 처리 실패입니다.

● 피크 경보의 미탐지·오경보 분석

- 정보 정책의 정의

- * 피크 시각 적중률이 20.4%이므로 경보는 '그날 하루가 위험한가'를 판정하는 일 단위로 설계했습니다. 15분 최대를 직접 학습한 분위수 0.9(P90) 예측이 학습 구간 15분 최대의 Q95를 넘는 시각이 하루에 한 번이라도 있으면 위험일로 판정합니다. 임계는 학습 기간마다 갱신되며 폴드별로 181 to 186이었습니다.

- 일 단위 정보 성능 (미탐지 0건)

- * 7 to 9월(CORE) 구간 내 완전한 24시간 평가가 가능한 69일을 대상으로 시뮬레이션한 결과, 실제 위험일을 단 하루도 놓치지 않았습니다(미탐지 0건, 재현율 100%).

표 3 - 2. 피크 정보 혼동 행렬

구분	실제 위험일	실제 안전일
정보 발령	42	2
정보 없음	0	25

- * 오경보는 2일(8월 17일, 9월 14일)로 정밀도는 95.5%였으며, 두 날 모두 실제 최대가 임계보다 12, 2 낮았던 고부하일이었습니다.
- * 정보율 63.8%는 평가 구간이 부하가 가장 높은 여름철이고, 미탐지를 0으로 두려고 보수적으로 임계를 잡은 결과입니다.

- 임계값 민감도와 운영 정책 선택

- * 정보 임계 기준을 Q95에서 Q97, Q98로 상향 조정해 본 결과, 정밀도는 95.5% → 94.9% → 100%로 큰 변동이 없었으나, 재현율은 100% → 88.1% → 64.3%로 떨어졌습니다.

표 3 - 3. 정보 임계 민감도

예측 모델	정보 임계	일 정밀도(%)	일 재현율(%)	일 정보율(%)	시간 정밀도(%)	시간 재현율(%)
15 분 최대 L1	Q95	100	64.3	39.1	59.8	31.5
15 분 최대 L1	Q97	100	26.2	15.9	64.3	8.5
15 분 최대 L1	Q98	100	7.1	4.3	71.4	2.3
15 분 최대 P90	Q95	95.5	100	63.8	57.4	84
15 분 최대 P90	Q97	94.9	88.1	56.5	64.9	57.3
15 분 최대 P90	Q98	100	64.3	39.1	71	35.7

- * 최대수요전력은 한 번의 초과로 1년 기본요금이 정해지므로, 정보 피로를 줄이는 이득(정보율 39.1%)보다 미탐지 비용이 훨씬 큼니다. 그래서 Q95를 기본 정책으로 정했습니다.

- * 같은 15분 최대 타깃에서 목적함수만 점 예측(L1)으로 바꾸어 같은 Q95 임계값에 적용하면 재현율은 64.3%에 그칩니다. 분위수 회귀(P90)가 미탐지를 줄인 핵심 요인입니다.

- 시간 단위 경보의 한계와 보완

- * 시간 단위로 채점하면 정밀도 57.4%, 재현율 84.0%로 낮아집니다. 비슷한 높이의 봉우리가 여럿이라 최댓값 시점 하나를 집어내기 어렵기 때문입니다.
- * 그래서 현장은 '오늘이 위험하다'는 일 단위 신호를 받고, 시간대 조치는 과거 피크 시각 분포를 기준으로 합니다. 가동일 일 최대는 8시 29.1%, 11시 18.9%, 13시 13.6%, 9시 11.7% 순이며, 이 4개 시각이 가동일 피크의 약 90%를 차지합니다. 새벽 일 최대는 비가동일의 값(평균 107)이라 경보 대상이 아닙니다.

● 영향요인 종합과 검증

- 평상시와 피크 시의 지배 요인 역전 재확인

- * 제2장 SHAP과 본 장의 오차 분석은 같은 결론입니다. 평상시 기준선은 생산계획(48.7%)과 과거 전력(33.7%)이 정하고, 피크 구간에서는 과거 전력(1.50배)과 기상(1.56배)의 비중이 커집니다. 고온 가동 구간 편향이 +0.13인 것은 모델이 기온 조건을 학습했다는 뜻이고, 남은 피크 과소예측은 회귀 모델의 특성입니다.
- * 정리하면 피크는 생산이 이루어져야 생기고(필요조건), 그 위에서 고온이 위험을 키우며(증폭 요인), 실제 높이는 과거 같은 요일의 부하 관성이 정합니다. 1장의 상관 역전, 2장의 SHAP, 본 장의 오차 구조가 모두 이 순서를 가리키며, 수치 근거는 제4장 기온 × 생산 교차표에 있습니다.

- 경보 판정의 미래 정보 누수(Data Leakage) 검증

- * 경보가 예측 시점(전날 자정)에 알 수 없는 당일 실제 전력을 쓰지 않았는지 확인하려고, 88일 치의 당일 이후 실제 전력을 지우거나 임의 값으로 바꾼 뒤 예측과 경보 판정을 176회 다시 수행했습니다. 예측값 변화는 0.0이었고 입력 피쳐와 경보 판정도 원본과 같았습니다(대상: 경보 경로 15분 최대 L1·P90).

- 오류 분석의 한계

- * 평가 구간 공휴일이 4일(부분 가동 2일)뿐이라, 최대 취약점인 부분 가동 공휴일 처리의 통계적 유의성을 담보하기 어렵습니다.
- * 경보 성능도 가동일 69일의 결과이며 독립 홀드아웃이 없고, 7 to 9월을 설정 선택에도 썼으므로 현장 성과는 다소 낮을 수 있습니다.
- * P90 예측은 포함률(Coverage) 캘리브레이션을 거치지 않았으므로 '90% 확률 상한'을 보장하지

않으며, 한전의 계약전력 초과 판정 기준과도 직접 연동되지 않습니다.

제4장. 현장 활용방안

● 하루 단위 운영 시나리오

- 전날 자정에 산출되는 3대 핵심 지표

- * 모델은 매일 자정에 다음 날 24시간을 예측해 시간별 전력 곡선, 일 최대 전력 추정치, 당일 피크 위험 여부를 냅니다. 쓰임새가 달라 산출물마다 다른 모델이 맞습니다(표 4-1).

표 4 - 1. 산출물별 담당 모델과 현장 용도

산출물	담당 모델	무엇을 내는가	검증된 성능	현장 용도
시간별 전력 예측	LightGBM h7_lag · L1	다음 날 24 시간 부하 곡선	MAE 6.57 (제 2 장 기준)	생산·교대 일정 검토
일 최대 전력 추정	LightGBM 분위 0.9	그날 최고점의 높이	MAE 8.61 · 편향 -0.16	기본요금 영향 판단
피크 위험 정보	15 분 최대 직접 P90	그날이 위험일인지 여부	재현율 100% · 정밀도 95.5%	당일 대응 발동

- 정보 신호에 따른 현장 조치 시나리오

- * 정보가 없는 날은 기존 일정대로 운전합니다(평가 69일 중 25일, 이 중 실제 위험일 0일).
- * 정보가 난 날은 설비 기동 계획을 다시 점검하고, 가동일 피크의 약 90%가 몰린 8·9·11·13시를 중점 관리 시간대로 둡니다.
- * 경보율 63.8%는 운영 부담이 될 수 있습니다. 현장 도입 시에는 학습 분위수(Q95) 대신 실제 계약전력을 절대 임계로 바꿔야 경보가 선택적으로 작동하며, 실행 옵션 하나(`python run_dashboard.py --threshold 값`)로 전환됩니다.

● 위험 조건의 구조적 이해와 사전 점검

- 생산은 필요조건, 기온은 증폭 요인

- * 일 생산량 하위 1/3에 해당하는 23일의 경우, 최고 기온이 30℃를 초과하는 폭염 조건에서도 실제 피크 발생일 비율은 0%였습니다. 즉, 기본적인 생산이 없으면 기온이 아무리 높아도 피크는 발생하지 않습니다.
- * 생산 중위 1/3에서는 기온이 오를수록 피크일 비율이 66.7%(9일) → 83.3%(12일) → 100%(2일)로, 상위 1/3에서도 71.4% → 100% → 100%로 올랐습니다. 30℃ 초과·중위 칸은 2일뿐이라 크기보다 방향을 읽어야 합니다.

표 4 - 2. 기온 X 생산 교차표

기온대	하위 1/3	중위 1/3	상위 1/3
26 도 이하	0% (4 일)	67% (9 일)	71% (7 일)
26-30 도	0% (7 일)	83% (12 일)	100% (10 일)
30 도 초과	0% (12 일)	100% (2 일)	100% (6 일)

- 전날 자정에 수행하는 3단계 점검 리스트

- * 위 구조를 운영자가 직관적으로 활용할 수 있도록 3단계 점검 항목으로 정리했습니다. 명일 일 생산계획이 상위 1/3 수준인지(피크일 비율 91.3%, 기준 대비 1.62배), 명일 가동 예정 시간이 18시간 이상인지(91.2%, 1.61배), 그리고 명일 예측 최고 기온이 26 to 30도 구간에 드는지입니다(75.0%, 1.33배).
- * 세 번째 항목을 '26 to 30도'로 좁힌 이유는, 30°C 초과는 피크일 비율이 40.0%(0.71배)로 오히려 기준보다 낮기 때문입니다(30°C 초과 20일 중 12일이 생산 하위 1/3). 기온은 반드시 생산 조건과 함께 읽어야 합니다.
- * 세 조건이 모두 겹치는 날은 정보와 관계없이 설비 가동 분산을 먼저 시행하고, 주말이나 생산 하위 1/3인 날은 피크일이 한 번도 없었으므로(0%) 추가 조치를 하지 않습니다.

● 현장 맞춤형 피크 전력 저감 방안

- 저감 전략의 4축 분리 검증

- * '생산일정 또는 설비가동 시점 조정'에는 성격이 다른 네 축이 섞여 있어 분리해 측정했습니다. A 상시 가동 분산, B 정보일 피크 시각 억제, C 날짜 간 생산일정 조정, D 하루 내 시간대별 생산 배분 조정이며, A·B는 채택, C는 보조, D는 기각입니다.
- * 저감폭은 모델 예측이 아니라 당일 최대와 2위 시각의 실측 차이로 계산했습니다. 모델은 '어느 날이 위험한가'까지만 답하므로 반사실 추론 모델을 세우지 않았습니다.
- * 시간대별 요금 차등이 없어 야간 이전은 인건비만 1.5배로 늘리므로, 모든 방안은 최대수요전력 자체를 낮추는 데 맞췄습니다.

표 4 - 3. 저감 축 4종의 검증 결과와 판정

저감 축	무엇을 바꾸나	측정 결과	현장 비용	판정
A 상시 가동 분산	7·8 시와 13 시의 동시 가동을 분산	8 시 상승폭 +48.6 · 13 시 +50.1	인건비 0 · 생산 손실 0	채택 (상시)
B 정보일 피크 시각 억제	그날 최대 시각 1 시간을 2 위 시각 수준까지 억제	연 최대 222 → 215.5 (50% 억제, 표 4-5)	인건비 0 · 생산 손실 0	채택 (정보일)
C 날짜 간 생산일정	고생산일을 분산 배치	일생산 17,000 이상에서 일 최대가 포화	생산 계획 변경 필요	효과 작음
D 하루 안 생산 배분	시간별 생산량을 재배분	반사실 검증 83 쌍 적중률 48.2% (우연 수준, $p = 0.670$)	모델이 배분 차이를 구분 못 함	기각

- 1순위 타겟: 설비 동시 기동 시각의 분산 (축 A)

- * 8시(+48.6)와 13시(+50.1)에 부하가 한꺼번에 오르며, 13시는 점심에 켜던(-54.6) 설비를 다시 켜는 상승입니다. 월 최대일 7개월 중 5개월의 피크가 이 기동 시각(7 to 9시·13시)이었습니다.
- * 이 5개월(1·3·5·8·9월)에서 기동 봉우리를 당일 2위 시각 수준으로 낮추면 그날 최대가 평균 8.0, 최대 12.0 내려갑니다. 월 최대수요전력에 반영되는 폭은 그 달 2위 일이 반치므로 이보다 작거나 같고(표 4-5의 A 열), 피크가 11시였던 7월은 0입니다.
- * 주요 설비군을 10 to 20분 간격으로 순차 기동하고 점심 복귀 시각을 설비별로 나눕니다. 추가 투자 없이 운전 규칙만 바꾸는 최우선 조치이며, 생산 총량과 배분을 바꾸지 않아 생산 손실과 인건비 증가가 없습니다.




그림 4 - 1. 시각별 전력 상승폭

- 2순위 타겟: 경보일의 피크 시각 집중 억제 (축 B)

- * 축 B는 경보일에만 그날 최대 시각 한 시간의 부하를 2위 시각 수준까지 억제하는 집중 조치입니다. 피크 시각과 무관하게 적용되어 월 최대일의 최대가 평균 7.9, 최대 13.0(7월) 내려가며, 재현율 100% 경보가 대상일을 놓치지 않는다는 것이 전제입니다.
- * 축 D와 달리 생산을 재배분하지 않고 특정 시각의 부하만 누르며, 저감폭도 실측 차이로 계산하므로 축 D의 기각 사유가 적용되지 않습니다.
- * 연 최대 전력을 만든 날의 피크가 기동 시각이 아니어서, 축 A만으로는 기본요금도 내려가지 않습니다(연 최대 저감폭 0).

- 3순위 타겟: 날짜 간 생산일정 조정 (축 C)

- * 날짜 간 물량 이동은 효과가 제한적이며, 근거는 모델 판단이 아니라 실측된 포화 구조입니다.
- * 일 생산이 11,823 → 17,178 → 19,705로 늘 때 일 최대는 165.9 → 179.7 → 185.3으로

오르지만, 24,228에서도 185.2로 멈춥니다. 17,000 이상에서는 일 최대가 180 to 185에 포화되어 물량을 옮겨도 최대치가 크게 달라지지 않습니다(제1장의 생산 800 포화가 일 단위에서도 나타남).

- * 따라서 경보일에 한해 고부하 작업 일부를 경보 없는 날로 옮기는 보조 수단으로만 씁니다.

- 하루 내 시간대별 생산 배분 조정 (축 D, 기각)

- * 총생산은 그대로 두고 시간별 배분만 바꾸는 축은 기각했습니다. 조건을 맞춘 날짜 쌍 83개에서 모델의 방향 적중률이 48.2%(단측 이항검정 $p = 0.670$)로 우연과 구별되지 않아, 효과를 예측할 수 없기 때문입니다.

● 저감 효과의 금액 환산

- 금액 변동의 유일한 통로 (기본요금)

- * 단가는 계절별 세 값뿐이고 총생산을 줄이지 않으므로 전력량 요금도 고정입니다. 금액이 움직이는 통로는 최대수요전력 기본요금뿐입니다.
- * 요금적용전력은 당월과 직전 11개월의 최대수요전력 중 가장 큰 값이므로, 1년에 한 번의 최고점이 12개월 기본요금을 정합니다. 그래서 평균 피크가 아니라 연중 최대 한 점을 얼마나 낮추는지만 봅니다.

- 절감액 산출 모델

- * 절감액 산출 모델은 연 절감액(원) = $\Delta P \times k \times U \times 12$ 로 정의했습니다. ΔP 는 연 최대수요전력의 감소분, k 는 전력 열을 kW로 변환하는 환산계수, U 는 기본요금 단가(원/kW·월)입니다.
- * 기본요금 단가(U)는 2021년 1월 1일 시행된 한전 고시 단가를 적용했습니다. $k = 1$ 이면 최대수요전력이 222kW로 계약전력 300kW 미만인 '산업용(갑) I'(저압 5,550원, 고압A 선택 I 6,490원, 선택II 7,470원)이, $k = 4$ 이면 약 888kW로 300kW 이상인 '산업용(을)' 고압A(선택 I 7,220원, 선택II 8,320원, 선택III 9,810원)가 해당합니다. 데이터에 계약 종별 정보가 없어 각각 세 가지를 모두 산출했습니다.
- * 환산계수(k)는 15분 전력 열의 특성(순시 전력인지 사용량인지)이 명확하지 않으므로 보수적 기준치인 1을 대입하고, 누적 사용량일 경우의 환산값인 4를 병기했습니다.

표 4 - 4. 절감액 모델식의 입력값

기호	뜻	값	출처	구분
ΔP	연 최대수요전력 저감폭	조치별 0.0 to 13.0	15 분 최대 기준 시물레이션	계산됨
k	전력 열 → kW 환산계수	1 (대안 4)	15 분 열 단위가 데이터에 없음 (순시 kW 면 1, 15 분 사용량이면 4)	현장 확인
U	기본요금 단가(원/kW·월)	k=1: 5,550 / 6,490 / 7,470 · k=4: 7,220 / 8,320 / 9,810	2021-01-01 시행 한전 요금표. k=1 → 산업용(갑) I (300kW 미만), k=4 → 산업용(을) 고압 A(300kW 이상). 계약 종별은 데이터에 없음	종별 확인
n	적용 개월	12	요금적용전력 = 당월·직전 11 개월 중 최대	제도 전제

- 저감폭(ΔP) 산출과 축 A/B 투트랙 구성의 근거

- * 저감 수단을 성격이 다른 두 축으로 나누어 시물레이션했습니다. 복제일 161일을 제외한 고유일만을 대상으로, 월 2위일도 함께 내려가도록(한 날만 낮출 경우 절감액이 0이 되는 구조 방지) 계산했습니다.
- * [축 A의 한계]: 7월의 축 A 저감폭은 0.0입니다. 이는 연 최대 전력(222)이 발생한 2021년 7월 19일의 피크 시각이 기동 시각(7 to 9시·13시)이 아닌 11시였기 때문입니다. 즉, 상시 기동 분산(축 A)을 아무리 강하게 적용해도 식의 ΔP 는 0이 되어 연 절감액은 발생하지 않습니다.
- * [축 B의 필수성]: 반면, 당일 피크 시각 억제(축 B)를 적용하면 연 최대 전력이 222에서 215.5(50% 억제) 또는 209.0(100% 억제)으로 내려가 비로소 실질적인 금액이 도출됩니다.
- * 축 A가 무의미하다는 뜻은 아닙니다. 투자나 인건비 상승이 없는 무비용 조치여서, 평상시에는 축 A로 기동 봉우리를 낮추고 재현율 100% 경보가 울리는 날에만 축 B로 연 최대를 낮추는 투트랙이 재무적으로 유효합니다.

표 4 - 5. 조치별 월 최대수요전력 저감폭

월	고유 가동 일수	표본	월 최대일	피크 시각	월 최대 수요 전력	A 30%	A 50%	A 100%	B 50%	B 100%
1	4	부족	0116	8	185	1.5	2.5	5	2.5	5
3	2	부족	0321	8	208	1.8	3	6	3	6
5	14	충분	0517	8	192	1.8	3	6	3	6
6	2	부족	0627	12	31	0	0	0	1	2
7	27	충분	0719	11	222	0	0	0	6.5	13
8	31	충분	0811	8	218	3.3	5.5	11	5.5	11
9	14	충분	0910	9	204	3.9	6.5	8	6	8

- 조건별 연 절감액 종합

- * 식 산출 결과, 기준 시나리오인 '축 B 50% 억제' 시 ΔP 는 6.5이며, 연 절감액은 $k =$

1(산업용(갑)Ⅰ)에서 432,900 to 582,660원, $k = 4$ (산업용(을) 고압A)에서 2,252,640 to 3,060,720원입니다. 피크를 완전히 억제(100%)하면 ΔP 는 13.0으로 늘어, $k = 1$ 에서 865,800 to 1,165,320원, $k = 4$ 에서 최대 6,121,440원(을 고압A 선택Ⅲ)까지 커집니다.

- * 축 A만으로는 연 최대 저감폭이 0이어서 절감액도 0이며, 축 A와 B를 병행해도 연 최대일의 피크가 11사이므로 연 절감액은 축 B 단독과 같습니다. 다만 7 to 9월 월평균 저감폭은 50% 수준에서 6.00이 7.42로 커져 부하 안정성이 개선됩니다.

표 4 - 6. 조치별 연 절감액

조치	연 최대 ΔP	CORE 월평균 ΔP	k	$\Delta P \cdot k$ (kW)	5,550 / 7,220 원	6,490 / 8,320 원	7,470 / 9,810 원
B 경보일 피크 시각 억제 (50%)	6.5	6	1	6.5	432900	506220	582660
B 경보일 피크 시각 억제 (50%)	6.5	6	4	26	2252640	2595840	3060720
B 경보일 피크 시각 억제 (100%)	13	10.67	1	13	865800	1012440	1165320
B 경보일 피크 시각 억제 (100%)	13	10.67	4	52	4505280	5191680	6121440

● 금액 외의 부가적 운영 효과

- 대가(Cost)가 0인 조치 구조

- * 인건비는 9 to 17시 1.0, 그 외 1.5로 고정되어 있습니다. 축 A·B는 부하를 야간이 아닌 주간 쪽으로 옮기므로 야간 할증이 늘지 않고, 7·8시 기동을 9시 이후로 분산하는 만큼 오히려 줄어듭니다. 생산 총량을 유지하고 장비 도입도 없습니다.
- * 결과적으로 k 와 U 값이 미확정된 상태에서도, 해당 정책이 창출하는 순효과의 부호가 양수임은 보장됩니다. 만약 부하를 야간으로 넘긴다면 저감폭은 커지겠지만 인건비 할증으로 인해 득실을 장담할 수 없습니다. 현장에 확신을 주기 위해 무비용 구간 내의 조치만을 엄선해 제안했습니다.

- 일주일 전(D-7) 경보로 확보되는 선제적 조치 시간(Golden Time)

- * 경보를 하루 전이 아닌 7일 전(D-7)에 발령하도록 시뮬레이션한 결과, D-7 기준 분위 0.9 정책의 재현율은 97.4%로 D-1(100.0%) 대비 2.6%p 하락에 그쳤고, 15분 최대 기준에서도 D-7 재현율은 97.6%였습니다(표 4-7은 평가일 72일 기준의 별도 측정으로, 제3장 표 3-2의 69일과 다릅니다).
- * 전달 통보만으로는 교대 편성과 정비 일정을 바꾸기 어렵지만, 7일의 여유가 있으면 미리 대처할 수 있습니다.

표 4-7. 경보 리드 타입

설정	임계전력	정밀도(%)	재현율(%)	경보율(%)	경보일	실제위험일	일치율(%)
D-7 · 분위 0.9	175.3	86.4	97.4	61.1	44	39	90.3
D-1 · 분위 0.9	175.3	86.7	100	62.5	45	39	91.7
D-7 · 15 분 최대	184.3	93.2	97.6	61.1	44	42	94.4
D-7 · 점 예측	175.3	87.9	74.4	45.8	33	39	80.6
D-1 · 점 예측	175.3	84.8	71.8	45.8	33	39	77.8

- 설비 여유 용량 확보 및 계측 체계 개선 지표 도출

- * 최대수요전력이 지속적으로 낮아지면 계약전력과 변압기 용량에 물리적 룸(Room)이 확보되어, 증설 투자 없이도 향후 생산을 확대할 여지가 생깁니다.
- * 본 분석을 통해 공장 데이터의 핵심 공백 3가지(15분 단위 전력의 성격 k , 계약 종별 확인 U , 복제일 및 누락일 데이터 무결성)가 명확히 식별되었습니다. 이 3가지가 보완되면 표 4-6은 하나의 금액으로 확정됩니다. 본 분석은 예측과 함께, 공장이 스마트 팩토리로 고도화하려면 '무엇을 추가로 계측해야 하는가'도 짚어 줍니다.

● 종합: 현장 도입 시 함께 고려해야 할 조건

- 수치 해석 시 주의해야 할 보수적 접근 가이드

- * 경보 임계 Q95는 '평소보다 전력을 많이 쓰는 날'을 찾는 상대 기준입니다. 계약전력 초과 판정이나 절대 절감액으로 해석하면 안 되며, 현장 이식 시에는 실제 계약전력을 절대 임계로 넣어야 합니다.
- * 표 4-5의 100% 열은 조치를 완벽히 달성한 이론 상한입니다. 옹근 부하는 인접 시각으로 일부 전이되므로, 금액은 50% 억제를 기준 시나리오로 제시했습니다.
- * 부분 가동 공휴일의 과대예측(제3장)은 운영 체계에도 남아 있으므로, 공휴일이나 반일 근무일에는 경보보다 현장 판단과 실제 기동 계획을 우선합니다.

제5장. 창의성 및 차별성

● 탐색 결과를 운영 규칙까지 관통시킨 해석

- 상관이 사라진 현상의 해석과 운영 규칙화

- * 일 생산량과 일 최대 전력의 상관은 전체 0.85에서 가동일만 보면 0.094로 떨어집니다(표 1-2). 이를 '무관함'이 아니라 '필요조건의 충족'으로 해석했습니다. 생산이 이루어지는 날만 남아 변별력을 잃었을 뿐 생산은 피크가 통과해야 하는 관문이며, 임계값을 바꿔도($0 \rightarrow 0.73$, $10,000 \sim 15,000 \rightarrow 0.08$) 결론이 같습니다.
- * 이 해석을 prod_cap, cool, thi 피쳐로 옮겼고, 피크 구간에서 thi는 2.25배, cool은 1.54배 더 쓰인 반면 원본 기온은 0.92배였습니다(SHAP). 같은 순서를 제4장 교차표로 확인해 전날 자정 3단계 점검으로 정리했습니다. 하나의 탐색 결과가 피쳐 설계, 모델 해석, 오류 분석, 현장 점검까지 이어집니다.

● 요금 제도에서 역산한 이중 타깃 설계

- 요금 산정 단위에서 정한 타깃과 목적함수

- * 과제의 기본 타깃은 시간 평균 전력이지만 기본요금은 15분 최대로 산정됩니다. 시간 평균에 환산 계수를 곱하는 방법은 예측 시점에 예측 오차가 겹치므로, 경보에는 15분 최대를 별도 타깃으로 직접 학습했습니다.
- * 산출물마다 필요한 성질(작은 평균 오차, 편향 없음, 위험일 미탐지 방지)이 달라 시간별 곡선은 L1, 일 최대 추정은 분위수 0.9, 피크 경보는 15분 최대 P90으로 목적함수를 나눴습니다.
- * 그 결과 일 최대 추정 MAE는 10.93에서 8.61로, 편향은 +6.80에서 -0.16으로 줄었고, 같은 타깃같은 Q95 임계에서 위험일 재현율은 L1 64.3%, P90 100%였습니다. 목적함수만 바꿔 생긴 차이입니다.

● 직관에 반하는 데이터 처리 결정

- 어제 데이터의 배제와 의도적 결측

- * 주 단위 패턴이 강해 토요일을 금요일 값으로 예측하면 오차 82.8, 지난주 토요일 값이면 12.4입니다. 24시간 전 시차를 뺀 h7_full이 full보다 MAE가 1.10 낮았고(표 2-5), 덕분에 7일 전 경보도 재현율 97.4%를 유지했습니다(표 4-7).
- * 휴무 구간은 대체값으로 메우지 않고 일부러 결측으로 두었고(결측 21.5%), 이를 그대로 학습하는 LightGBM을 택했습니다(피크 MAE 16.19, RandomForest 21.13). 결측

여부(lag168_na)와 대체 후보(lag_best)를 더해 MAE를 6.79에서 6.57로 낮췄으며, 개선은 예측이 몰린 8월에 집중되었습니다.

● 수치보다 검증 규칙을 앞세운 설계

- 누수 교정과 판정 기준

- * is_off가 당일 최대 전력에서 과생된 값을 확인하고 생산계획군으로 옮기자 no_plan MAE가 13.36에서 25.32로 나빠졌지만, 교정 후 값을 기대 성능으로 보고했습니다. 교정 전 수치는 현장에서 재현되지 않기 때문입니다.
- * 55개 설정이 같은 평가 행(2,092행)과 판단 기준(1,708행)을 쓰고, 시드 표준편차보다 작은 차이는 개선으로 보지 않았습니다. 이 기준에 따라 복제일 가중치 0.1과 0.3의 우열은 MAE가 아닌 피크 MAE와 시드 안정성으로 가렸습니다.
- * 정보 경로는 당일 이후 실제 전력을 지우거나 바꾼 176회 재실행에서 예측값 변화 0.0, 판정 100% 일치를 확인해, 재현율 100%·정밀도 95.5%가 예측 시점에 알 수 없는 정보 없이 얻은 값을 보였습니다.

● 기각 결과와 미확정 값의 명시

- 반사실 질문의 자격 검증과 미확정 값의 대입표

- * 생산 일정을 바꿨을 때의 효과는 관측된 일정으로만 학습한 모델에 학습하지 않은 인과를 묻는 질문이므로, 모델이 답할 자격이 있는지 먼저 시험했습니다.
- * 조건(같은 요일 유형, 기온 차이 $\pm 1.5^{\circ}\text{C}$, 생산 총량 차이 $\pm 10\%$ 이내)이 유사하면서 시간별 배분만 다른 실제 날짜 쌍 83개를 추출하여, 어느 쪽 피크가 더 높은지를 모델이 맞히도록 테스트했습니다. 그 결과 적중률은 48.2%(단측 이항검정 $p = 0.670$)로 우연 수준(50%)과 구별되지 않았습니다. 83쌍에서 유의($p \leq 0.05$)하려면 50쌍(60.2%) 이상을 맞혀야 합니다.
- * '효과가 없다'가 아니라 '효과를 주장할 근거가 없다'고 보고 축 D를 기각했습니다. 예측 모델에서도 기각한 설정(표 2-8)과 추가 15가지 기법을 사유와 함께 남겼습니다.
- * 연 최대수요전력 저감폭(ΔP)만 실측 데이터로 계산하고, k 와 U 는 향후 현장에서 확인하여 대입할 수 있는 '대입표' 형태로 설계하여 제시했습니다(제4장 표 4-4, 표 4-6). 금액을 하나로 단정하지 않는 대신, 어떤 값을 확인하면 금액이 확정되는지와 무엇을 추가로 계측해야 하는지를 함께 제시했습니다.

● 지능형 의사결정 지원 화면 (대시보드)

- 시스템 구성 및 핵심 산출물 통합

- * 현장 책임자가 예측, 경보, 저감 권고를 한눈에 보도록 오프라인 HTML 운영 화면을 만들어 제출하였습니다. 결과가 파일 안에 들어 있어 서버 없이 더블클릭으로 열리고(보기 전용), 새 예측 CSV를 불러오면 경보를 다시 판정합니다. 작업 조건을 바꿔 권고를 다시 계산하려면 로컬 서버 모드(python run_dashboard.py)로 실행합니다.




그림 5 - 1. 운영 화면 1 (예측 곡선, 경보, 작업 조건 · 2021-09-09)




그림 5 - 2. 운영 화면 2 (추천 일정 비교 · 2021-09-09, 가정 부하)

- 일정 조정 권고 알고리즘의 동작 원리

- * 현장의 실무 제약(각 작업의 소요 시간, 가동 허용 시간대, 선후행 작업 관계, 고정 여부, 동시 가동 허용 작업 수)을 지키는 범위에서 일 최대 전력이 가장 낮아지는 작업 배치를 '분기한정법(Branch and Bound)'으로 탐색합니다. 작업 부하를 모두 알지 못하면(또는 예측 전력과 맞지 않으면) 저감량을 계산하지 않고, 경보 시간대와 겹치는 작업 시간을 줄이는 쪽으로 권고합니다.
- * 2021년 9월 9일 예측에 예시 작업 4건(부하는 가정값)을 넣으면 2건의 시작 시각만 옮겨, 가정 부하를 더한 일 최대 P90이 199.1에서 195.1로, 경보 기준(187.0) 이상인 시간이 8시간에서 7시간으로 줄어듭니다(그림 5-2). 가정값으로 계산한 예시이며 실측 저감량은 아닙니다.
- * 화면은 설비를 직접 제어하지 않고 권고안만 보여 주며, 안전 확인을 포함한 적용 여부는 현장 책임자가 정합니다. 잘못된 입력은 계산하지 않고 이유를 표시하며, 부분 가동 공휴일처럼 모델이 약한 날에는 현장 판단을 우선합니다.

● 차별성 종합

- 성과의 출처

- * 본 과제의 차별성은 새로운 알고리즘보다 문제를 다루는 방식에 있습니다. 탐색 결과를 운영 규칙까지 관통시킨 해석, 요금 제도에서 역산한 이중 타깃 설계, 직관에 반하는 데이터 처리 결정, 수치보다 검증 규칙을 앞세운 설계, 기각 결과와 미확정 값의 명시, 의사결정 지원 화면이 그것입니다.
- * 예측 알고리즘은 LightGBM 하나만 사용했으며, 목표선(단순 규칙) 대비 전체 MAE를 71%, 피크 구간 MAE를 65% 줄였고(제2장), 평가 구간 69일에서 위험일을 하루도 놓치지 않았습다(제3장). 다만 이 수치는 설정 선택에 쓴 7 to 9월 구간의 결과이고 독립 검증 구간이 없어, 현장 성능은 이보다 낮을 수 있습니다.

제6장. 코드 구성 및 재현성

● 제출 자료의 구성

- 디렉터리 구성

- * 제출 소스코드는 총 55개 파일로 구성되며, 분석에 사용된 모든 코드와 학습용 데이터, 테스트 구간 예측 결과가 포함되어 있습니다. 중간 산출물인 그림과 중간 CSV는 모두 코드로 재생성되므로 제출물에서 제외하여, 평가자가 받는 자료가 곧 실행 가능한 최소 집합이 되도록 정리했습니다.

표 6 - 1. 제출 자료의 구성

구분	경로	개수	내용
분석 모듈	src/	36	전처리·피처·모델·오차분석·경보·저감·보고서 데이터 생성
자동 테스트	tests/	7	경보 정책·미래정보 누수·일정 추천·화면 통신 규약 검증
실행 스크립트	루트	3	run_all.py · run_dashboard.py · Resource optimization AI.py
운영 화면	web/	1	현장 운영 플래너 (제 5 장)
학습용 데이터	dataset/	1	okm_augumented_2021.csv (원본, 수정하지 않음)
예측 결과	outputs/	3	테스트 구간 예측 파일, 결과 화면과 데이터
환경·문서	루트	4	environment.yml · requirements.txt · README · 사용법

- 실행 환경의 고정

- * 환경은 conda용 environment.yml과 pip용 requirements.txt 두 가지로 제공하여, 평가 환경에 conda가 설치되어 있지 않더라도 실행할 수 있도록 했습니다.
- * 성능 수치를 좌우하는 네 개 패키지는 정확한 버전으로 고정했습니다. Python 3.12, numpy 2.5.3, pandas 3.0.6, scikit-learn 1.9.1, LightGBM 4.7.0이며 본 보고서의 모든 수치가 이 환경에서 산출되었습니다.
- * 행렬 연산 라이브러리는 OpenBLAS로 명시 고정했습니다. MKL 빌드에서는 numpy 행렬곱 수행 시 역추적(Traceback) 없이 인터프리터가 종료되는 현상이 재현되었기 때문이며, 환경 파일에 확인 명령과 함께 그 사유를 주석으로 남겼습니다.
- * 참고로 Python 3.11과 numpy 2.4.6 조합에서도 동일한 수치가 산출되는 것을 교차 확인했습니다(RandomForest 기준 9.96 / 18.55 / 21.13 동일). 따라서 평가 환경이 두 조합 중 어느 쪽이든 본 보고서의 결과가 재현됩니다.

● 실행 방법

- * 목적에 따라 두 가지 실행 경로를 제공합니다. 전체 분석 과정을 그대로 재현하는 경로와, 핵심 결과만 한 번에 확인하는 경로입니다.

- 경로 1. 전체 파이프라인 재현 (python run_all.py)

- * 전처리부터 보고서 표·그림 데이터 생성까지 21단계가 순서대로 실행되며, 본 보고서의 모든 표와 그림이 outputs 폴더 아래에 다시 생성됩니다. 단계 간 의존 관계는 실행 순서로 보장되므로 평가자가 개별 스크립트를 순서대로 호출할 필요가 없습니다.

표 6 - 2. 파이프라인 21단계의 구성

목음	단계	내용
데이터 준비	1 to 5	전처리, EDA, 반복 패턴 분석, 피쳐 생성
모델 개발	6 to 8	베이스라인 4 종, 설정 비교 24 개, 약점 공략 31 개
성능·오류 분석	9 to 10	조건별 오차 분석, SHAP 영향요인 분석
피크·경보	11 to 15	위험조건, D10 경보 검증, 분위 비교·누수 검증, 저감방안
추론·결과 생성	16 to 21	테스트 구간 예측, 최종 성능 요약, 운영 화면 생성

- * 소요 시간은 7번과 8번 두 단계가 대부분을 차지합니다. 두 단계 모두 24개에서 31개 설정을 시드 3개씩 반복 학습하기 때문입니다.

- 경로 2. 단일 파일 실행본 (python "Resource optimization AI.py")

- * 전처리부터 저감방안까지 9개 과정을 한 파일에 담아 외부 모듈 의존 없이 단독으로 실행됩니다. 약 4분 만에 본 보고서의 핵심 수치가 콘솔에 표로 출력되고 결과 화면이 함께 갱신됩니다.
- * --serve 옵션을 붙이면 실행 후 로컬 화면이 자동으로 열리며, 분석 근거 대시보드와 제5장의 운영 플래너가 하나의 주소에 탭으로 제공됩니다. 해당 서버는 127.0.0.1로만 열리므로 외부 네트워크에서는 접속되지 않습니다.

● 코드 구조와 평가 규약의 단일 출처

- 중앙 집중식 설계

- * 제2장에서 기술한 "모든 스크립트가 동일한 평가 기준을 불러온다"는 원칙을 코드 구조로 강제했습니다. 평가 대상 행, 폴드 분할, 시드, 복제일 가중치, 최종 설정이 모두 src/model.py 한 곳에 상수로 정의되어 있고, 나머지 모듈은 이를 가져다 쓸 뿐 자체적으로 재정의하지 않습니다.
- * 이 구조 덕분에 평가 조건을 바꾸려면 한 파일만 수정하면 되며, 반대로 어떤 스크립트도 자기에게만 유리한 평가 기준을 사용할 수 없습니다.

표 6 - 3. 핵심 모듈과 담당 범위

모듈	담당 범위	주요 산출물
preprocess.py	원본 정제, 복제일·휴무일·손상일 판별	모든 단계의 공통 입구
features.py	피쳐 생성, 피쳐 세트 4 종 정의	full / h7_full / h7_lag / h7_no_plan
model.py	평가 규약, 롤링 폴드, 최종 설정 4 종	설정 비교표 (표 2-4 to 2-8)
alarm_policy.py	D10 경보 정책 정의	15 분 최대 P90 ≥ 학습 Q95
peak_alarm_max15.py	경보 검증, 임계 민감도, 누수 감사	표 3-2 to 3-3
predict_test.py	테스트 구간 예측 파일 생성	제출용 예측 CSV

● 재현성을 보장하는 네 가지 장치

- 평가셋 고정

- * 평가 대상 행(고유일 2,092행, 판단 기준 1,708행)은 모든 실험에서 동일하게 유지됩니다. 학습 데이터의 양만 실험에 따라 달라지므로, 설정 간 성능 차이가 모델이 좋아져서인지 쉬운 데이터만 평가해서인지 혼동될 여지가 없습니다.

- 시드 고정과 시드 평균 보고

- * 모든 설정을 시드 0, 1, 2로 세 번 반복 학습하고 평균과 표준편차를 함께 보고합니다. 또한 설정 간 차이가 시드 표준편차보다 작으면 개선으로 보지 않는다는 판정 기준을 적용하여, 우연한 변동을 성과로 기록하지 않았습니다.

- 실행본의 자기 검증

- * 분석 코드와 단일 실행본이 따로 수정되어 서로 다른 값을 내는 상황을 막기 위해, 실행본이 종료 직전 자신의 결과를 본 보고서의 표와 대조합니다. 여섯 항목이 모두 일치해야 종료 코드 0을 반환하며, 하나라도 어긋나면 경고와 함께 1을 반환합니다.

표 6 - 4. 실행본의 자기 검증 항목

검증 항목	기준값	대조 대상
시간 단위 MAE	6.57	표 2-6
피크 구간 MAE	12.49	표 2-6
일 최대 MAE (분위 0.9)	8.61	표 2-12
피크 경보 일 재현율	100.0%	표 3-2
피크 시각 적중률	20.4%	표 2-12
학습 행 수	5,788	표 2-3

- 자동화된 테스트

- * 7개 테스트 모듈을 두어 경보 정책의 정의, 예측 시점 입력의 무결성, 일정 추천 로직, 화면 통신 규약을 검증합니다. 특히 제3장의 미래 정보 누수 검증(88일 분량, 176회 재수행, 예측값 변화 0.0)은 일회성 확인이 아니라 테스트로 고정되어 있어, 코드를 수정하더라도 누수가 다시 발생하면 즉시 드러납니다.

● 재현 과정에서 발견하여 바로잡은 사항

- * 재현성은 선언이 아니라 실제로 맞추어 본 결과여야 한다고 보고, 보고서 원고의 수치와 코드 출력을 전수 대조했습니다. 그 과정에서 발견한 두 가지를 기록으로 남깁니다.

- 동일한 설정에서 값이 달라진 사례 (RandomForest)

- * 비교 모델의 성능이 코드 경로에 따라 9.96과 10.10으로 다르게 산출되는 현상을 확인했습니다. 설정표상으로는 트리 수, 리프 최소 표본, 결측 처리, 피쳐 세트까지 완전히 동일한 상태였습니다.
- * 원인은 학습 가중치를 전달하는 방식이었습니다. 모든 가중치가 1.0인 경우 한쪽은 가중치를 전달하지 않고 다른 쪽은 1.0으로 채운 배열을 전달했는데, scikit-learn의 RandomForest는 가중치 인자를 받으면 부트스트랩 표본 추출 경로가 달라져 결과가 바뀝니다. LightGBM에서는 두 방식이 동일하게 동작하므로 LightGBM 기반 수치는 모두 일치했고 RandomForest만 어긋나 있었습니다.
- * 이를 일치시킨 결과 [표 2-4]의 9.96 / 18.55 / 21.13이 정확히 재현되었습니다. 문서상 "같은 설정"이라는 기술만으로는 동일한 결과가 보장되지 않으며, 실제 호출 방식까지 맞추어야 한다는 점을 확인한 사례입니다.

- 환경 파일의 의존성 충돌

- * 환경 파일이 Python 3.11과 numpy 2.5.3을 함께 고정하고 있었으나, numpy 2.5.3은 Python 3.12 이상을 요구하므로 환경 생성 자체가 실패하는 상태였습니다.
- * Python 3.12로 상향한 뒤 환경을 처음부터 새로 생성하여 전체 파이프라인과 테스트를 재실행했고, 본 보고서의 모든 수치가 그대로 재현되는 것과 자기 검증 여섯 항목이 전부 일치하는 것을 확인했습니다.

● 평가자 실행 시 참고사항

- 실행 전 확인할 사항

- * 학습된 모델 파일은 포함하지 않았습니다. 제공된 학습용 데이터로 매 실행 시 재학습하는 구조이므로, 제출된 코드와 데이터만으로 전처리부터 결과 생성까지 전 과정이 재현됩니다.
- * 데이터를 교체하여 검증하실 경우 dataset 폴더의 원본 파일을 동일한 파일명으로 덮어쓰면 되며, 18개 변수의 구성과 이름은 유지되어야 합니다. 이때 자기 검증 항목([표 6-4])은 본 보고서 작성 시점의 데이터를 기준으로 한 값이므로 불일치로 표시되는 것이 정상입니다.
- * 본 보고서의 수치는 제2장에서 밝힌 대로 7 to 9월(CORE) 구간을 설정 선택의 기준으로 활용했으므로 선택 편향이 내재되어 있습니다. 재현 결과가 보고된 값과 일치하더라도, 완전히 독립적인 데이터에서의 성능은 이보다 다소 낮을 수 있습니다.

경진대회 만족도 조사 완료 페이지 캡처 화면

